

أهداف التعلم

- التمييز بين البيانات الأولية والثانوية، وتوضيح الحالات التي تكون فيها كلٌّ منها مناسبة.
- شرح آلية أخذ العينات، ووصف كيف يمكن أن يؤدي التحيز في العينة إلى استنتاجات خاطئة رغم أنها تبدو واثقة.

يبدأ التحليل الجيد بجمع بيانات مناسبة للسؤال. فالبيانات الأولية تُجمع مباشرة لغرض الدراسة الحالية، أما البيانات الثانوية فهي بيانات موجودة مسبقًا يعاد استخدامها لغرض جديد. وعندما يكون فحص المجتمع الإحصائي كله صعبًا أو مكلفًا، يمكن دراسة عينة منه. وكلما كانت طريقة الاختيار أفضل وأقل تحيزًا، زادت الثقة في تعميم النتائج، مع مراعاة حجم العينة وتصميم الدراسة وعدم اليقين.

؟ السؤال الرئيس: كيف تجمع بيانات يمكنك الوثوق بها، وكيف يمكن لعينة صغيرة أن تمثل مجتمعًا إحصائيًا كاملًا بعدالة؟

📌 ملحوظة مهمّة

1. مرحلة جمع البيانات

(1) يتقدم تحليل البيانات عبر تسلسل "الجمع ← التنظيم ← التحليل"، بعد توضيح الغرض. وفي **(جمع البيانات)**، المرحلة الأولى، من الضروري التخطيط لما سيُجمع من بيانات وكيف، بما يتماشى مع غرض التحليل.

(2) إذا كانت البيانات غير مناسبة للسؤال أو منخفضة الجودة، فقد تكون النتائج مضللة مهما كان التنظيم والتحليل دقيقين. لذلك تعد طريقة الجمع مرحلة مهمة تؤثر بقوة في جودة التحليل.

2. البيانات الأولية والبيانات الثانوية



البيانات الأولية تُجمع مباشرة للسؤال الحالي؛ والثانوية بيانات موجودة مسبقًا يعاد استخدامها.

(1) **البيانات الأولية**: بيانات يجمعها الباحث أو الفريق مباشرة لغرض الدراسة أو التحليل الحالي، مثل بيانات الاستبيانات والمقابلات والملاحظات والتجارب. ويمكن تصميم طريقة الجمع لتناسب السؤال، لكن الجودة تعتمد على التصميم والتنفيذ، وقد يتطلب الجمع وقتًا وجهدًا وتكلفة.

(2) **البيانات الثانوية**: بيانات موجودة مسبقًا، جُمعت لغرض سابق ثم يعاد استخدامها، سواء جمعها آخرون أو الباحث نفسه سابقًا. قد توفر وقتًا وتكلفة، لكن يجب فحص طريقة جمعها وتعريفاتها ونقصها وتحيزاتها ومدى مناسبتها للسؤال الحالي.

(3) قد تكون البيانات الأولية مناسبة جدًا لسؤال محدد، لكن موثوقيتها لا تكون عالية تلقائيًا؛ فهي تعتمد على جودة التصميم والتنفيذ. وقد توفر البيانات الثانوية معلومات جاهزة لا تحتاج إلى جمعها مرة أخرى، لكنها قد تناسب السؤال أو لا تناسبه. ويمكن الجمع بين النوعين بحسب الغرض والقيود.

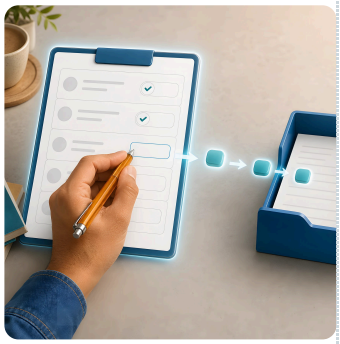
⭐ خريطة الدرس

الفكرة الأساسية:

يبدأ التحليل الجيد بالجمع الجيد: البيانات الأولية تُجمع حديثًا لغرض محدد؛ والبيانات الثانوية موجودة مسبقًا؛ وأخذ العينات يدرس جزءًا من المجتمع الإحصائي لتقدير الكل – ولا يدعم استنتاجات صحيحة سوى العينة غير المتحيزة.

المفاهيم الأساسية:

- جمع البيانات
- البيانات الأولية / الثانوية
- المجتمع الإحصائي والعينة
- أخذ العينات (العشوائي البسيط، الطبقي)
- تحيز أخذ العينات



الجمع السليم للبيانات هو أساس البيانات الموثوقة.

مصطلحات أساسية

جمع البيانات – المرحلة الأولى: التخطيط لما سيُجمع وكيف.

البيانات الأولية – تُجمع حديثًا لغرض محدد.

البيانات الثانوية – سبق أن جمعها آخرون.

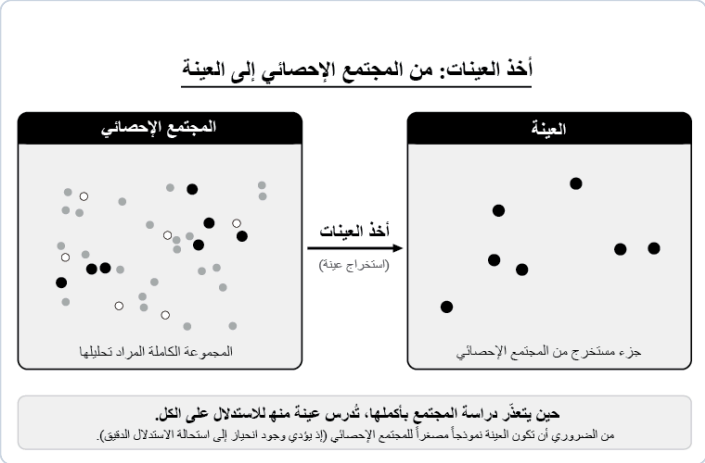
3. أخذ العينات



نحاول اختيار عينة تمثل المجتمع قدر الإمكان، ونتجنب طرق الاختيار التي تزيد التحيز.

(1) **المجتمع الإحصائي**: جميع الأفراد أو العناصر التي نريد أن تنطبق عليها الدراسة. و**العينة**: جزء منه ندرسه ونريد أن يمثله قدر الإمكان. وتسمى دراسة جميع الوحدات حصرًا شاملًا أو تعدادًا في بعض السياقات، وتسمى دراسة عينة مختارة مسح عينة.

(2) **(أخذ العينات)**... اختيار عينة من المجتمع الإحصائي. تختلف موثوقية الاستنتاجات المُتحصَّل عليها اختلافًا كبيرًا حسب طريقة أخذ العينات.



الشكل 5.1.1 – أخذ العينات: من المجتمع الإحصائي إلى العينة

(3) قد يقلل الاختيار العشوائي بعض أنواع تحيز الاختيار إذا طُبق بطريقة سليمة، وقد يدعم تعميم النتائج مع مراعاة حجم العينة وإطار المعاينة وعدم الاستجابة وأخطاء القياس.

الطريقة	الوصف
(المعاينة العشوائية البسيطة)	اختيار وحدات عشوائيًا من إطار المجتمع، بحيث تكون لكل وحدة فرصة معروفة ومتساوية في النموذج البسيط
(المعاينة الطبقية)	تقسيم المجتمع إلى فئات مهمة لسؤال الدراسة، ثم اختيار عينة من كل فئة وفق تصميم محدد

(4) المعاينة العشوائية البسيطة طريقة أساسية وسهلة الفهم، لكنها تحتاج إلى إطار مناسب يمكن الاختيار منه عشوائيًا. وقد تساعد المعاينة الطبقية على تمثيل فئات مهمة وتحسين الدقة إذا اختيرت الطبقات والنسب بطريقة مناسبة.

4. تحيز أخذ العينات

(1) **تحيز المعاينة**: انحراف يحدث عندما تجعل طريقة اختيار العينة بعض أفراد المجتمع أكثر أو أقل احتمالًا للتمثيل، فتكون النتائج أقل تمثيلًا للمجتمع وقد يصبح تعميمها غير موثوق.

(2) أمثلة على مصادر مختلفة للانحراف في الاستطلاع

💡 توقّف وفكّر

التعداد السكاني الحكومي الذي تُنزّله – هل هو بيانات أولية أم ثانوية بالنسبة لك؟

نوع التحيز	الوصف	مثال
(تحيز الاختيار الذاتي)	تحيز ناتج عن استجابة من يرغبون في الاستجابة فقط	في استطلاع عبر الويب، يستجيب فقط من لديهم اهتمام عالٍ
(تحيز الاستجابة)	تحيز ناتج عن اختيار المستجيبين إجابات تبدو مرغوبة بدلًا من استجابة دقيقة	الإبلاغ عن "وقت دراسة" أطول مما كان عليه فعليًا
(تحيز الوقت/ الموقع)	تحيز في التغطية أو الاختيار بسبب قصر وقت الاستطلاع أو مكانه على فئات معينة	إجراء الاستطلاع أمام محطة في بعد ظهيرة أيام الأسبوع، مما يستبعد الموظفين والطلاب

(3) يمكن تقليل تحيز المعاينة بتحسين إطار المعاينة وطريقة اختيار المشاركين وتوقيت الوصول إليهم. أما صياغة الأسئلة وطريقة الإجابة فتساعدان على تقليل أخطاء القياس وتحيز الاستجابة؛ وهما مشكلتان مختلفتان عن تحيز المعاينة.

الفكرة الرئيسة

يعتمد التحليل الموثوق على الجمع، لا على الحساب وحده. اختر البيانات الأولية أو الثانوية بما يناسب الغرض، وادرس عينة عندما يكون المجتمع الإحصائي كبيرًا جدًا، واستخدم أخذ العينات العشوائي (البسيط أو الطبقي) بحيث تعكس العينة الكل، وانتبه لتحيز أخذ العينات – فالعينة غير المتوازنة تعطي استنتاجًا واثقًا لكنه خاطئ.

مصطلحات أساسية

المجتمع الإحصائي – المجموعة الكاملة التي يشملها التحليل.

العينة – الجزء الذي يُمسح فعليًا.

تحيز أخذ العينات – عينة غير عادلة لا تمثل الكل تمثيلًا صحيحًا.

توقّف وفكّر

استطلاع عبر الويب يمكن لأي شخص المشاركة فيه – أصوات من تغيب، وأي نوع من التحيز هذا؟

مثال محلول

(1) ضع علامة ○ أو × أمام كل عبارة (أ - د) حسب صحتها.

أ تشير البيانات الأولية إلى بيانات سبق جمعها ونشرها من قِبل آخرين.

ب يُسمى اختيار عينة من مجتمع إحصائي أخذ العينات.

جـ المعاينة الطبقية طريقة يُقسَّم فيها المجتمع الإحصائي إلى طبقات، وتُختار عينة عشوائيًا من كل طبقة.

د عند وجود تحيز في أخذ العينات، قد لا تكون الاستنتاجات المُتحصَّل عليها قابلة للتطبيق على المجتمع الإحصائي ككل.

(2) طابق كل وصف (1، 2) لطريقة أخذ عينات بالخيار الأنسب من الخيارات أدناه (أ، ب).

1 اختيار عينة من المجتمع الإحصائي بالصدفة، دون تحيز.

2 تقسيم المجتمع الإحصائي إلى طبقات مثل الجنس أو الفئة العمرية، والاختيار عشوائيًا من كل طبقة.

[الخيارات] أ المعاينة الطبقية ب المعاينة العشوائية البسيطة

الحلّ

(1)

أ البيانات الأولية هي بيانات تُجمع حديثًا لتناسب غرضًا محددًا. أما البيانات التي سبق جمعها ونشرها من قِبل آخرين فهي بيانات ثانوية. لذلك، ×.

ب تعريف صحيح لأخذ العينات. لذلك، ○.

جـ تعريف صحيح لالمعاينة الطبقية. لذلك، ○.

د وصف صحيح لأثر تحيز أخذ العينات. لذلك، ○.

(2)

1: الاختيار دون تحيز بالصدفة هو المعاينة العشوائية البسيطة. **ب**

2: التقسيم إلى طبقات والاختيار عشوائيًا من كل منها هو المعاينة الطبقية. **أ**

تدرّب

1 أجب عن الأسئلة التالية.

1. ما اسم البيانات التي تُجمع مباشرة لغرض الدراسة الحالية؟
2. ما اسم البيانات الموجودة مسبقًا التي نعيد استخدامها لغرض جديد؟
3. ما مصطلح اختيار عينة من مجتمع إحصائي؟
4. ما مصطلح كون طريقة اختيار العينة متحيزة ولا تعكس بشكل صحيح الحالة الفعلية للمجتمع الإحصائي؟

2 أجب عن الأسئلة التالية.

(1) من الخيارات التالية (أ - د)، اختر الأنسب كطريقة لجمع بيانات أولية.

أ استخدام بيانات إحصائية نشرتها جهة حكومية.

ب إنشاء استبيان يناسب غرض المرء الخاص وجمع الردود.

ج الاستشهاد بأرقام من تقرير صادر عن جمعية صناعية.

د استخدام بيانات استطلاع من دراسة أجراها شخص آخر سابقًا كما هي.

(2) لكل موقف استطلاع (1، 2)، اختر طريقة أخذ العينات الأنسب من الخيارات أدناه (أ، ب).

1 عند دراسة وقت الدراسة لدى جميع طلاب مدرسة، تريد اختيار العينة مع مراعاة الفروق في الاتجاهات بين الصفوف.

2 تريد استيعاب آراء جميع الناخبين المؤهلين في مدينة دون تحيز.

[الخيارات] أ المعاينة العشوائية البسيطة ب المعاينة الطبقية

(3) من الخيارات التالية (أ - د)، اختر الأنسب كمثال حدث فيه تحيز في أخذ العينات.

أ مسح 100 طالب اختيروا عشوائيًا من جميع طلاب المدرسة بالقرعة.

ب تقسيم جميع السكان إلى طبقات عمرية ومسح عينة عشوائية من كل طبقة.

ج مقابلة المارة أمام المحطة في بعد ظهيرة أيام الأسبوع والإبلاغ عن النتائج باعتبارها "آراء جميع المواطنين."

د تصميم صياغة سؤال الاستطلاع بعناية بحيث يستطيع المستجيبون الإجابة بصدق.

📝 سؤال على نمط الامتحان

اشرح لماذا يمكن لعينة متحيزة أن تجعل التحليل عديم القيمة حتى عندما تكون الحسابات صحيحة. **[6]**

راجع: العينة بوصفها نموذجًا مصغرًا للمجتمع الإحصائي.

💡 توقّف وفكّر

أي خيار يجمع بيانات جديدة صمّمتها *أنت* – وأيها يعيد استخدام بيانات الآخرين فقط؟

⚙️ فكّر كمهندس: ابحث ثم قرر

تريد مدرستك معرفة المدة التي يقضيها الطلاب عادةً في التنقل إلى المدرسة يوميًا، لكن لا يمكنك مسح الجميع. أنت تصمم كيفية اختيار عينة وسؤالها.

1 · خطط للعينة. حدّد المجتمع الإحصائي وطريقة اختيار عينة تقلل التحيز وتمثل الفئات المهمة. ويمكنك جمع بيانات تجريبية من 8 إلى 10 زملاء لتجربة السؤال، مع التنبيه إلى أن هذه المجموعة ليست بالضرورة عينة ممثلة للمدرسة.

2 · حلّل مصدر الانحراف. حدّد مجموعة قد تستبعدها طريقتك، واشرح أثر غيابها. ثم حدّد هل المشكلة في اختيار العينة أو تغطيتها، أم في طريقة إجابة المشاركين، ولا تجمع الأنواع المختلفة تحت اسم واحد.

3 · قرّر. اختر المعاينة العشوائية البسيطة أو الطبقية لهذا الاستطلاع وبرّر اختيارك من واقع التحدي الذي وجدته في الخطوة 2 – فكّر فيما إذا كان التنقل يختلف فعلًا بين فئات فرعية يمكن تمييزها هنا. **في أزواج،** قارنوا الطرق واتفقوا على التغيير الوحيد الذي سيقلل التحيز أكثر من غيره.

☐ **سؤال من يسهل الوصول إليه** ☐ **التخطيط لعينة عادلة وممثلة**

قدّم دليلًا على إجابتك.

هل تواجه صعوبة؟ ابدأ من من قد يُستبعد. اسأل نفسك: هل قد يجيب جزء من المدرسة بشكل مختلف تمامًا عن البقية – مجموعة كاملة، أو طلاب لا يرون استطلاعك أبدًا؟ إذا كان من المحتمل أن تختلف فئة فرعية بشكل منهجي، فالسؤال الحقيقي هو كيف تمنح كل فئة فرعية فرصة عادلة *قبل* اختيار طريقتك. حدد الفئات الفرعية المهمة هنا، ثم دع ذلك يوجّه اختيارك.

مصطلحات أساسية

المعاينة العشوائية البسيطة – يُختار بمحض الصدفة.

المعاينة الطبقية – يُقسَّم إلى طبقات، ثم يُختار من كل منها.

🌍 طبّق ما تعلمته

مركز تسوق يستطلع فقط زوار بعد ظهر يوم السبت ويُبلغ عن النتائج باعتبارها "ما يفكر فيه جميع عملائنا." اذكر نوع التحيز، واشرح من يُستبعد، وصف تغييرًا واحدًا من شأنه أن يجعل العينة أكثر عدالة.

❓ إجابة السؤال الرئيس

أجاب الدرس عن السؤال الرئيس: كيف نجمع بيانات مناسبة ونختار عينة؟ تجمع البيانات الأولية مباشرة لغرض الدراسة الحالية، بينما يعاد استخدام البيانات الثانوية الموجودة مسبقًا. ولا يضمن أي نوع الجودة تلقائيًا؛ بل يجب فحص التصميم والتنفيذ ومدى ملاءمة البيانات للسؤال. وعندما يصعب دراسة المجتمع كله نختار عينة. قد يقلل الاختيار العشوائي تحيز الاختيار، وتساعد المعاينة الطبقية على تمثيل فئات مهمة، لكن التعميم يعتمد أيضًا على إطار المعاينة والحجم وعدم الاستجابة والقياس. ويجب التمييز بين تحيز المعاينة الناتج عن الاختيار وتحيز الاستجابة الناتج عن طريقة الإجابة.

تمارين

1 اختبر فهمك: أجب عن الأسئلة الآتية دون الرجوع إلى قسم «ملحوظة مهمة»، ثم راجع إجاباتك.

2 اقرأ الفقرة التالية وأجب عن كل سؤال.

في تحليل البيانات، من المهم التخطيط لما سيُجمع وفق السؤال. يمكن استخدام (1) التي تُجمع مباشرة لغرض الدراسة الحالية، أو (2) الموجودة مسبقًا التي يعاد استخدامها. وعندما يصعب دراسة المجتمع كله، تُستخدم (3) لاختيار جزء منه. وإذا جعلت طريقة الاختيار بعض فئات المجتمع أكثر أو أقل احتمالًا للتمثيل، يحدث (4) وقد تصبح النتائج أقل قابلية للتعميم.

1. املأ الفراغات (1) - (4).

3 أجب عن الأسئلة التالية.

(1) من الخيارات التالية (أ - د)، اختر الأنسب كمثال على بيانات ثانوية.

أ ردود استبيان جُمعت من طلاب في صف المرء الخاص.

ب إحصاءات سكانية نشرتها الحكومة.

ج حركة مرور على طريق تنقل مدرسي لاحظها المرء وسجّلها بنفسه.

د سجلات مقابلة صمّمها المرء وأجراها بنفسه.

(2) من الخيارات التالية (أ - د)، اختر الخيار الذي يصف طرق أخذ العينات بأفضل شكل.

أ المعاينة العشوائية البسيطة طريقة يختار فيها القائم بالاستطلاع تفضيليًا المشاركين الأسهل جمعًا.

ب المعاينة الطبقية طريقة يُقسَّم فيها المجتمع الإحصائي إلى طبقات، وتُختار عينة عشوائيًا من كل طبقة.

ج المعاينة العشوائية البسيطة طريقة يُقسَّم فيها المجتمع الإحصائي إلى طبقات، ويُختار ممثل من كل طبقة.

د المسح الشامل طريقة يُمسح فيها جزء فقط من المجتمع الإحصائي.

(3) من الخيارات التالية (أ - د)، اختر ما لا يُعد طريقة مناسبة لتقليل تحيز أخذ العينات.

أ اختيار المشاركين دون تحيز من المجتمع الإحصائي بأكمله.

ب تقييد توقيت وموقع الاستطلاع، وجمع الردود فقط من أشخاص في ظروف محددة.

ج اختيار العينة مع مراعاة طبقات المجتمع الإحصائي (الفئة العمرية، الجنس، إلخ).

د تصميم صياغة أسئلة الاستطلاع بحيث يستطيع المستجيبون الإجابة بصدق.

⭐ الخلاصة

تذكّر:
اجمع البيانات الصحيحة (الأولية مقابل الثانوية)، وادرس عينة عادلة من المجتمع الإحصائي، واستخدم أخذ العينات العشوائي (البسيط أو الطبقي) بحيث تعكس العينة الكل، واحترس من تحيز أخذ العينات.

⭐ فكّر وتحدَّ نفسك

تأمل: فكّر في استطلاع رأي عبر الإنترنت شاهدته. من كانت أصواتهم غائبة على الأرجح عنه، ولماذا؟

تحدٍّ: يمكنك استطلاع رأي 40 طالبًا فقط من أصل 800 طالب في مدرستك حول جدول جديد. صف بالضبط كيف ستختار هؤلاء الـ40 لتجنب التحيز، واذكر المجموعة الواحدة التي ستحرص على تمثيلها.



الدرس 5-2

تنظيف البيانات وتحويلها

أهداف التعلم

- شرح كيفية التعامل مع القيم المفقودة، والقيم الشاذة (المتطرفة)، والبيانات المكررة عند تنظيف مجموعة البيانات.
- وصف عمليات تحويل أنواع البيانات (الربط والتجميع).

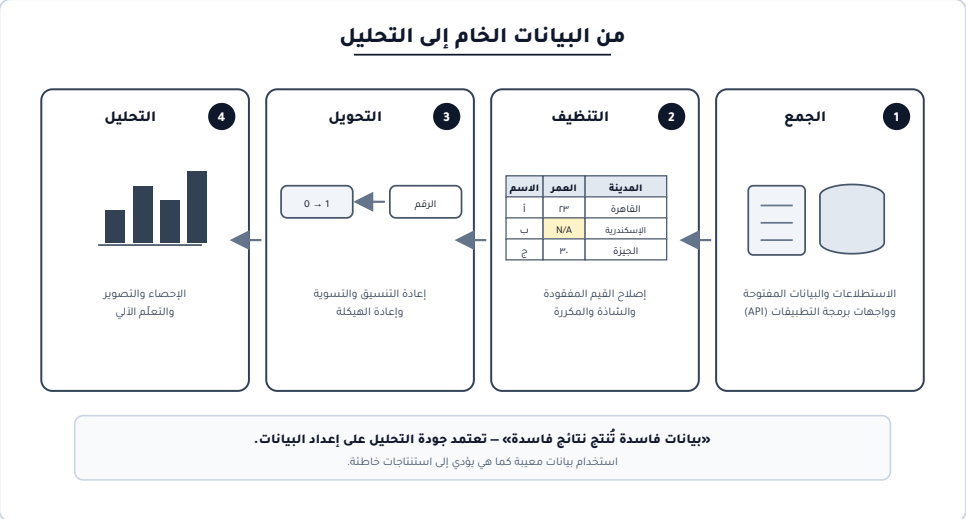
تصل البيانات الحقيقية فوضوية: خلايا فارغة، قيمة أكبر بعشر مرات من اللازم، نفس الصف مُدخَل مرتين، تواريخ مكتوبة بثلاث طرق مختلفة. قبل أن يُوثَق بأي تحليل، يجب تنظيف البيانات وتحويلها لتناسب السؤال المطروح. هناك قاعدة في علوم الحاسب – "مدخلات خاطئة – مخرجات خاطئة" – تعني أن الحساب الدقيق على بيانات معيبة لا يزال يعطي إجابة معيبة. هذا الدرس يتناول كيفية تحويل البيانات الخام إلى بيانات يمكن الاعتماد عليها فعليًا.

؟ السؤال الرئيس: لماذا يجب تنظيف البيانات وتحويلها قبل التحليل، وما الخيارات التي ينطوي عليها كل إصلاح؟

📌 ملحوظة مهمّة

1. مراحل تنظيف البيانات وتحويلها

(1) قد تحتاج البيانات المجمعة إلى تنظيف أو تحويل قبل التحليل. **تنظيف البيانات** هو اكتشاف مشكلاتها وتصحيحها أو التعامل معها بطريقة مناسبة، أما **تحويل البيانات** فيعد الصيغ أو البنية لتناسب السؤال وطريقة التحليل.



الشكل 5.2.1 – من البيانات الخام إلى التحليل: الجمع، التنظيف، التحويل، التحليل

(2) تؤثر جودة التحضير بقوة في جودة النتائج، لكن لا توجد سلسلة إصلاح واحدة تناسب كل البيانات: فالقرارات تعتمد على نوع المشكلة وسؤال التحليل.

2. التعامل مع القيم المفقودة



عالج القيم الفارغة وقيّم القيم الشاذة قبل التحليل.

⭐ خريطة الدرس

الفكرة الأساسية:

نادرًا ما تكون البيانات الخام جاهزة للاستخدام مباشرة. يعالج التنظيف القيم المفقودة والقيم الشاذة والتكرارات؛ ويحوّل التحويل الأنواع، ويعيد ضبط المقياس، ويعيد تشكيل البيانات لتناسب الغرض. "مدخلات خاطئة – مخرجات خاطئة" – تعتمد جودة أي تحليل على هذا التحضير.

المفاهيم الأساسية:

- تنظيف البيانات / تحويل البيانات
- القيم المفقودة، القيم الشاذة، التكرارات
- تحويل نوع البيانات
- التحويل الكمي / التوحيد القياسي
- إعادة التشكيل (المحور، الربط، التجميع)

مصطلحات أساسية

تنظيف البيانات – إصلاح القيم المفقودة والقيم الشاذة والتكرارات.

تحويل البيانات – إعادة تشكيل/ضبط مقياس البيانات لتناسب الغرض.

💡 توقّف وفكّر

خلية فارغة في استبيان – هل نحذف الصف، أم نملؤها، أم نضع عليها علامة؟ ما الذي يحدد ذلك؟

(1) قد تسبب القيم المفقودة مشكلات في بعض الحسابات أو تغير النتائج بحسب مقدارها وسببها ونمطها. ومن الطرق الشائعة الحذف أو التعويض أو الاحتفاظ بمؤشر يدل على أن القيمة مفقودة، وقد توجد طرق أخرى بحسب التحليل.

الاستجابة	الوصف	متى تُطبَّق
الحذف	إزالة سجل أو متغير إذا كان ذلك مناسبًا ولا يفقد معلومات مهمة أو يسبب تحيزًا مهمًا	قد يناسب عندما يكون الفقد قليلًا وفقد السجلات لا يسبب تحيزًا أو خسارة مهمة
التعويض	تقدير قيمة بديلة بطريقة مناسبة، وقد تكون بسيطة مثل الوسيط أو أكثر تقدمًا	يُختار بعد فهم سبب الفقد ونمطه وطريقة التحليل، مع فحص أثر التعويض في التوزيع والنتائج
وضع علامة	إنشاء مؤشر يوضح أن القيمة كانت مفقودة، أو استخدام فئة مناسبة إذا كان الغياب نفسه يحمل معنى	عندما يكون للغياب نفسه معنى (مثل حقيقة أن شخصًا ما رفض الإجابة)

(2) يعتمد الاختيار على مقدار الفقد وسببه ونمطه وغرض التحليل. وقد يغير التعويض البسيط بالمتوسط توزيع البيانات ويقلل التباين، خاصةً إذا كان الفقد كبيرًا؛ لذلك يجب فحص أثر الطريقة في النتائج.

3. التعامل مع القيم الشاذة والبيانات المكررة

(1) **القيم الشاذة** بعيدة عن معظم القيم، لكنها ليست أخطاء بالضرورة؛ فقد تنتج عن خطأ إدخال أو قياس، وقد تكون قيمة حقيقية نادرة. لذلك يجب التحقق من مصدر القيمة وتعريف المتغير قبل تعديلها.

(2) تبدأ معالجة القيم الشاذة بتحديد السبب.

① عندما يكون السبب خطأ في الإدخال أو القياس... صحّح القيمة أو احذفها

② إذا كانت القيمة صحيحة، فلا تحذفها لمجرد أنها بعيدة عن الباقي؛ قرر وفق سؤال التحليل وبسبب تحليلي واضح.

(3) قد تغير السجلات المكررة الحسابات، لكن لا يُحذف سجل مكرر ظاهريًا إلا بعد التأكد أنه تكرار غير مقصود لنفس الملاحظة أو الحدث؛ فقد تمثل السجلات المتشابهة أحداثًا حقيقية منفصلة.

4. تحويل نوع البيانات

(1) يجب الفصل بين **تغيير نوع البيانات**، مثل تحويل نص رقمي إلى رقم، وبين **توحيد الصيغ أو الترميز**، مثل توحيد كتابة التاريخ أو القيم الفئوية. وقد تحتاج البيانات إلى أحد هذه التحويلات أو أكثر.

نوع التحويل	الوصف	مثال
التحويل من نص إلى رقم	تحويل الأرقام المخزَّنة كنصوص إلى قيم رقمية يمكن استخدامها في الحسابات	"١٢٣" ← 123
توحيد صيغة التاريخ	مواءمة التواريخ ذات الصيغ المختلفة في صيغة واحدة	"2026/4/1"، "2026-04-01"، "01 Apr 2026" ← 2026-04-01
توحيد طريقة الكتابة	دمج القيم ذات المعنى الواحد في صيغة كتابة واحدة	مزيج من "ذكر/أنثى" و"M/F" ← موحَّد إلى "ذكر/أنثى"

(2) إذا اختلفت الصيغ أو الترميزات، فقد يعامل البرنامج القيم المتشابهة على أنها مختلفة. وإذا خُزنت الأرقام كنصوص، فقد تفشل بعض الحسابات أو تتعامل الأداة معها بوصفها نصوصًا. لذلك تُفحص الأنواع والصيغ قبل التحليل بحسب الأداة.

مصطلحات أساسية

القيمة المفقودة – قيمة غائبة.

القيمة الشاذة – قيمة بعيدة عن باقي القيم.

القيمة غير الطبيعية – قيمة شاذة ناتجة عن خطأ.



احذف السجلات المكررة فعليًا فقط.

توقّف وفكّر

الطول بالسنتيمتر والوزن بالكيلوغرام – لماذا قد تهيمن الأرقام الأكبر على التحليل؟

5. التحويل الكمي والتوحيد القياسي



التحجيم يغيّر مقياس المتغيرات عندما تكون الخوارزمية حساسة للمقياس.

(1) في بعض الخوارزميات الحساسة للمقياس، قد يكون للمتغير ذي النطاق الأكبر تأثير أكبر لمجرد مقياسه. عندئذ يمكن استخدام طريقة تحجيم مناسبة، مثل تحجيم Min-Max أو التوحيد القياسي.

الطريقة	الوصف	الغرض الرئيسي
تحجيم Min-Max	تحويل البيانات إلى نطاق من 0 إلى 1	وضع المتغيرات في نطاقات متقاربة عندما تحتاج الخوارزمية إلى ذلك
التوحيد القياسي	تحويل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1	التعبير عن بُعد القيمة عن المتوسط بوحدات من الانحراف المعياري

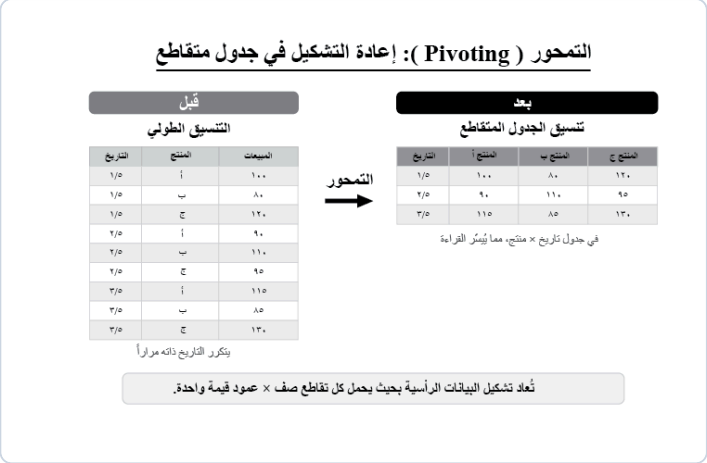
(2) يمكن لتحجيم Min-Max تحويل كل متغير إلى نطاق من 0 إلى 1 باستخدام حديه في البيانات. وقد يساعد ذلك خوارزمية حساسة للمقياس على التعامل مع متغيرات مختلفة دون أن يسيطر أحدها بسبب نطاقه، لكنه ليس مطلوبًا لكل تحليل.

(3) يطرح التوحيد القياسي المتوسط من كل قيمة ثم يقسم على الانحراف المعياري، فيصبح متوسط البيانات المستخدمة في الحساب 0 وانحرافها المعياري 1. وتمثل القيمة الجديدة عدد الانحرافات المعيارية عن المتوسط، مع اعتماد التفسير على شكل التوزيع.

6. إعادة تشكيل البيانات حسب الغرض

(1) **إعادة تشكيل البيانات**: تغيير بنية الجدول أو دمج الجداول أو تلخيصها بما يناسب السؤال. ومن عملياتها التحويل المحوري (Pivot) والربط والتجميع.

العملية	الوصف	مثال
التحويل المحوري (Pivot)	تحويل البيانات بين شكل طويل وعريض وفق صفوف وأعمدة محددة	إعادة تشكيل بيانات التاريخ والمنتج والمبيعات المرتبة عموديًا إلى جدول "التاريخ × المنتج"
(الربط)	دمج بيانات من جداول متعددة باستخدام مفتاح أو شرط مطابق	ربط سجل الطلاب وورقة الدرجات عبر "رقم الطالب" في جدول واحد
(التجميع)	حساب المجاميع والمتوسطات وما إلى ذلك لكل مجموعة وتلخيصها	حساب الإجمالي الشهري من المبيعات اليومية



الشكل 5.2.2 – تحويل المحور: إعادة تشكيل البيانات ذات الصيغة الطويلة إلى جدول متقاطع

(2) تعتمد العملية التي يجب إجراؤها على غرض التحليل. على سبيل المثال، إذا أردت رؤية "اتجاهات المبيعات الشهرية"، فأنت بحاجة إلى تجميع بيانات المبيعات اليومية حسب الشهر. من المهم توضيح غرض التحليل أولًا، ثم التخطيط لكيفية إعادة تشكيل البيانات.

الفكرة الرئيسة

التحضير يحدد الجودة. أصلح القيم المفقودة (احذف أو عوّض أو ضع علامة)، واحكم على القيم الشاذة حسب السبب، وأزل التكرارات الحقيقية، وحوّل أنواع البيانات ووحّد الصيغ، وأعد ضبط المقياس بالتحويل الكمي أو التوحيد القياسي حتى لا يهيمن أي متغير بحكم حجمه، وأعد التشكيل (المحور، الربط، التجميع) ليناسب السؤال – مدخلات خاطئة – مخرجات خاطئة.

توقّف وفكّر

هل يوم مبيعات ضخم في متجر ما دائمًا خطأ – أم قد يكون حقيقيًا؟

مثال محلول

(1) ضع علامة ○ إذا كانت العبارة صحيحة أو × إذا كانت خاطئة أمام كل عبارة (أ - د).

أ تنظيف البيانات هو عمل يُجرى قبل جمع البيانات.

ب استجابات القيم المفقودة هي الحذف والتعويض ووضع العلامة – ثلاث استجابات في المجموع.

جـ جميع القيم الشاذة ناتجة عن أخطاء في الإدخال أو القياس، لذا يجب حذفها دائمًا.

د التوحيد القياسي هو معالجة تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1.

(2) طابق كل وصف (1 - 3) مع المعالجة الأنسب من الخيارات أدناه (أ - ج).

1 تحويل البيانات إلى نطاق من 0 إلى 1

2 معالجة تربط مجموعات بيانات مختلفة عبر عنصر مشترك

3 معالجة تحسب المجاميع والمتوسطات وما إلى ذلك لكل مجموعة وتلخّصها

[الخيارات] أ التجميع ب الربط جـ التحويل الكمي

✓ الحلّ

(1)

أ تنظيف البيانات هو عمل ترتيب البيانات المجمَّعة، ويُجرى بعد الجمع. لذلك، x.

ب صحيح كاستجابات للقيم المفقودة. لذلك، ○.

جـ تشمل القيم الشاذة كلًا من القيم غير الطبيعية الناتجة عن أخطاء الإدخال والقيم التي تعكس الواقع. لا تُحذف دائمًا. لذلك، x.

د تعريف صحيح للتوحيد القياسي. لذلك، ○.

(2)

1: التحويل إلى 0-1 هو التحويل الكمي. **جـ**

2: الربط عبر عنصر مشترك هو الربط. **ب**

3: التلخيص حسب المجموعة هو التجميع. **أ**

📝 سؤال على نمط الامتحان

اشرح، باستخدام "مدخلات خاطئة – مخرجات خاطئة"، لماذا يهم تحضير البيانات بقدر أهمية التحليل نفسه. **[6]**

استعن بـ: إصلاح واحد للتنظيف وتحويل واحد.

تدرّب

1 أجب عن الأسئلة التالية.

1. ما المصطلح الذي يشير إلى المعالجة التي تملأ الأجزاء المفقودة من البيانات بقيم مثل المتوسط أو الوسيط؟
2. ما المصطلح الذي يشير إلى المعالجة التي تحوّل البيانات إلى نطاق من 0 إلى 1؟
3. ما المصطلح الذي يشير إلى المعالجة التي تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1؟
4. ما المصطلح الذي يشير إلى العملية التي تربط مجموعات بيانات متعددة عبر عنصر مشترك؟

2 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي لا يُعد استجابة مناسبة للقيم المفقودة.

أ عندما تكون القيم المفقودة قليلة والتأثير على الكل صغيرًا، احذف الصفوف التي تحتوي على قيم مفقودة.

ب عندما تكون القيم المفقودة موزعة عشوائيًا، املأ الأجزاء المفقودة بقيم مثل المتوسط.

جـ عندما يكون للغياب نفسه معنى، اترك علامة تشير إلى أن القيمة كانت مفقودة وحلّل البيانات.

د عوّض بالمتوسط وحلّل البيانات في العناصر التي يكون معظم بياناتها مفقودًا.

(2) لكل من الموقفين (1، 2)، اختر المعالجة الأنسب للبيانات من الخيارات أدناه (أ، ب).

1 تريد مواءمة بيانات التاريخ ذات الصيغ المختلطة مثل "2026/4/1" و"01-04-2026" و"01 Apr 2026".

2 تريد مقارنة متغيرات ذات وحدات ومقاييس مختلفة معًا، مثل الطول (بالسنتيمتر) والوزن (بالكيلوغرام).

[الخيارات] أ تحويل نوع البيانات (توحيد صيغة التاريخ) ب التحويل الكمي

(3) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف التعامل مع القيم الشاذة بأكبر قدر من الدقة.

أ جميع القيم الشاذة أخطاء في البيانات، لذا احذفها كلها فور اكتشافها.

ب بالنسبة للقيم الشاذة، حدّد السبب أولًا؛ صحّحها أو احذفها إذا كانت ناتجة عن أخطاء إدخال، واحتفظ بها من حيث المبدأ إذا كانت تعكس الواقع.

جـ القيم الشاذة لا تؤثر على التحليل، لذا لا حاجة لمعالجة خاصة.

د يمكن دائمًا حل القيم الشاذة عن طريق استبدالها بالمتوسط.

💡 توقّف وفكّر

إذا كان معظم العمود فارغًا، فهل ملؤه بالمتوسط يساعد – أم يخترع بيانات؟

⚙️ فكّر كمهندس: ابحث ثم قرر

جمع صفك استبيانًا عن وقت الشاشة اليومي، لكن الجدول الخام فوضوي: بعض الخلايا فارغة، وإدخال واحد يقرأ "9999" ساعة، والتواريخ مكتوبة بثلاث طرق مختلفة، وصفان يبدوان متطابقين. تقوم بتحضير البيانات للتحليل.

1 · **افحص البيانات.** اذكر كل مشكلة يمكنك رؤيتها في الجدول أعلاه؛ ولكل مشكلة، حدّد فئتها (قيمة مفقودة، قيمة شاذة، تكرار، أو مشكلة صيغة) واذكر بعبارة واحدة كيف ستشوّه التحليل إذا تُركت دون إصلاح.

2 · قرّر إصلاحًا وخطره. اختر طريقة التعامل مع القيم المفقودة بعد النظر إلى مقدار الفقد وسببه ونمطه، لا النسبة وحدها. وبالنسبة إلى «9999 ساعة»، تحقّق من مصدرها وتعريف المتغير قبل تقرير تصحيحها أو حذفها، فقد تكون خطأً أو وحدة مختلفة أو رمزًا ذا معنى.

3 · خطط للتحويل. حدّد تحويل الصيغة المطلوب لتجميع التواريخ، ثم اسأل: هل يحتاج هذا التحليل أصلًا إلى تحجيم عمود وقت الشاشة؟ وإذا نعم، فما الطريقة المناسبة؟ قارن الخطة مع زميل وحددا الإصلاح الأكثر احتمالًا لتشويه النتائج.

☐ **تحليل الجدول الخام كما هو** ☐ **تنظيفه وتحويله أولًا**

قدّم دليلًا يدعم إجابتك.

هل تواجه صعوبة؟ لا يوجد ترتيب إلزامي واحد لكل حالات التنظيف. افهم المشكلة أولًا، ووحّد الصيغ اللازمة، وتحقق من القيم غير المعتادة، وعالج الفقد، ولا تحذف إلا التكرارات غير المقصودة بعد التحقق منها.

🌍 طبّق ما تعلمته

يسرد جدول مبيعات متجر مبيعات كل يوم للمنتجات A Bg Cg في صفوف منفصلة، لكن المدير يريد صفًا واحدًا لكل يوم مع عمود لكل منتج. سمِّ عملية إعادة التشكيل المطلوبة، وسمِّ العملية الأخرى المطلوبة للحصول على الإجمالي الشهري لكل منتج.

❓ إجابة السؤال الرئيس

أجاب الدرس عن السؤال الرئيس: لماذا ننظف البيانات ونحوّلها؟ يكتشف التنظيف مشكلات مثل القيم المفقودة وغير المعتادة والتكرارات، ويعالجها بحسب سببها ونمطها وسؤال التحليل؛ فلا يُحذف سجل مكرر ظاهريًا أو قيمة بعيدة قبل التحقق. ويجب الفصل بين تغيير نوع البيانات وتوحيد الصيغ والترميز. وإذا كانت الخوارزمية حساسة للمقياس، يمكن استخدام Min-Max أو التوحيد القياسي، ولا يلزم التحجيم لكل تحليل. كما تعيد عمليات Pivot والربط والتجميع تشكيل الجداول لتناسب السؤال. كل قرار يحتاج إلى تبرير وفحص لأثره في النتائج.

مصطلحات أساسية

المحور – صفوف طويلة ← جدول صفوف × أعمدة.

الربط – ربط مجموعات البيانات عبر عنصر مشترك.

التجميع – التلخيص حسب المجموعة.

تمارين

1 اختبر فهمك: أجب عن الأسئلة الآتية دون الرجوع إلى قسم «ملحوظة مهمة»، ثم راجع إجاباتك.

2 اقرأ الفقرة التالية وأجب عن كل سؤال.

قد تحتاج البيانات إلى (1) لاكتشاف مشكلاتها والتعامل معها، و(2) لتغيير الصيغ أو البنية بما يناسب التحليل. ومن طرق التعامل مع الفقد (3) إلى جانب الحذف أو الاحتفاظ بمؤشر للفقد. وإذا كانت الخوارزمية حساسة للمقياس، يمكن استخدام (4) لتحويل القيم إلى نطاق 0-1، أو (5) لتحويلها إلى عدد الانحرافات المعيارية عن المتوسط.

1. املأ الفراغات (1) - (5).

3 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يمثل تحويل نوع البيانات.

أ ملء القيم المفقودة بالمتوسط.

ب توحيد صيغ مثل "2026/4/1" و"01 Apr 2026" إلى "2026-04-01".

جـ مواءمة مقاييس الطول والوزن إلى نطاق بين 0 و1.

د تجميع المبيعات اليومية في إجماليات شهرية.

(2) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف التحويل الكمي والتوحيد القياسي بأكبر قدر من الدقة.

أ التحويل الكمي هو معالجة تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1.

ب التوحيد القياسي هو معالجة تحوّل البيانات إلى نطاق من 0 إلى 1.

جـ يُستخدم التحويل الكمي لمواءمة البيانات ذات الوحدات المختلفة في صورة قابلة للمقارنة.

د يُستخدم التوحيد القياسي لتكبير مقياس المتغيرات.

(3) لكل معالجة (1 - 3)، حدّد ما إذا كانت تقابل المحور أو الربط أو التجميع.

1 ربط سجل الطلاب وورقة الدرجات عبر "رقم الطالب" في جدول واحد.

2 حساب الإجماليات الشهرية من بيانات المبيعات اليومية.

3 إعادة تشكيل مبيعات المنتجات اليومية في صورة جدول "التاريخ × المنتج".

[الخيارات] أ المحور ب الربط جـ التجميع

⭐ الخلاصة

تذكّر:
نظّف أولًا (القيم المفقودة، القيم الشاذة، التكرارات)، ثم حوّل (حوّل الأنواع، طبّق التحويل الكمي أو التوحيد القياسي، أعد التشكيل بالمحور والربط والتجميع). كل إصلاح هو حكم يحدده الغرض – مدخلات خاطئة – مخرجات خاطئة.

⭐ فكّر وتحدَّ نفسك

تأمّل: لماذا قد يؤدي "ملء" البيانات المفقودة أحيانًا إلى تضليل أكبر من تركها فارغة؟

تحدٍّ: لديك عمود استبيان واحد 70% من إجاباته فارغة. ناقش ما إذا كنت ستعوّض أو تضع علامة أو تحذف العمود، واذكر الشرط الوحيد الذي قد يغيّر اختيارك.



أهداف التعلم

- شرح مفهوم البيانات المفتوحة، مع تحديد أهم المصادر الموثوقة لها.
- وصف كيفية الحصول على البيانات عبر واجهة برمجة التطبيقات (API)، وشرح أهمية شروط الاستخدام وذكر المصدر.

توجد مصادر كثيرة توفر بيانات مفيدة بشروط تسمح بإعادة استخدامها. لكن الإتاحة العامة أو المجانية وحدها لا تجعل البيانات مفتوحة؛ فالانفتاح يتطلب ترخيصًا أو شروطًا واضحة تسمح بالوصول وإعادة الاستخدام وإعادة التوزيع. وقد يكون الوصول بالتنزيل أو عبر API أو بطريقة أخرى. لذلك يجب تقييم المصدر وطريقة جمع البيانات وحداثتها وملاءمتها للسؤال، ثم الالتزام بالترخيص ومتطلبات الإسناد.

؟ السؤال الرئيس: من أين تأتي البيانات المفتوحة الموثوقة، وكيف تجلبها البرامج، وما القواعد التي تحكم استخدامها؟

📌 ملحوظة مهمّة

1. استخدام البيانات المفتوحة

(1) عند استخدام بيانات مفتوحة، تحقق من أربعة أمور: المصدر وجودته، وطريقة الوصول، والترخيص أو شروط الاستخدام، ومدى مناسبة البيانات لسؤال التحليل. تساعد هذه الخطوات على الاستخدام المسؤول، لكن جودة النتيجة تعتمد أيضًا على جودة البيانات والمنهج.

(2) قد تنشر الجهات الحكومية والمنظمات والباحثون والشركات بيانات مفتوحة، لكن الترخيص والجودة والتعريفات تختلف من مجموعة إلى أخرى. اختر مصدرًا يناسب السؤال، وافحص الجهة الناشرة وتاريخ التحديث وطريقة الجمع والترخيص.

2. مصادر البيانات المفتوحة الرئيسية

(1) فيما يأتي أمثلة على بوابات ومنصات يمكن أن توفر بيانات مفيدة، مع ضرورة تقييم كل مجموعة وشروطها.

المزوّد	الوصف	الاستخدامات الرئيسية
World Bank) (Open Data	إحصاءات عن الاقتصاد والسكان والتعليم والصحة لدول مختلف أنحاء العالم	يمكن استخدامها للمقارنات الدولية إذا كانت التعريفات والفترات الزمنية مناسبة للسؤال
(UN Data)	إحصاءات دولية تنشرها الأمم المتحدة والوكالات التابعة لها	موضوعات دولية متعددة، مع التحقق من مصدر المؤشر وتعريفه
(Kaggle)	منصة تُنظَّم عليها مسابقات لتحليل البيانات، وتُتاح فيها مجموعات بيانات في مجالات متنوعة للعامة؛ ويجب تقييم مصدر كل مجموعة وترخيصها	الحصول على بيانات لدراسة وبحوث التعلّم الآلي

(2) تختلف طرق الوصول من مصدر إلى آخر؛ فقد يكون التنزيل مباشرًا، أو عبر API، أو بأدوات أخرى يوفرها المصدر.

⭐ خريطة الدرس

الفكرة الأساسية:

تأتي البيانات المفتوحة من مزودين موثوقين (World Bank Open Data، UN Datag، Kaggleg)؛ يمكن تنزيلها من متصفح أو جلبها بواسطة برنامج عبر واجهة برمجة تطبيقات (غالبًا ما تُعيد بيانات بصيغة JSON)؛ ولكل مجموعة بيانات شروط استخدام يجب اتباعها ومصدر يجب الإشارة إليه.

المفاهيم الأساسية:

- البيانات المفتوحة
- World Bank Open Data / UN (United Nations) Data / Kaggle
- واجهة برمجة التطبيقات (API) / نقطة النهاية (endpoint) / JSON
- شروط الاستخدام
- الإشارة إلى المصدر



البيانات المفتوحة عامة ومتاحة لإعادة الاستخدام مجانًا.

مصطلحات أساسية

البيانات المفتوحة – بيانات متاحة للعموم ليستخدمها أي شخص.

World Bank Open Data – إحصاءات الدول عن الاقتصاد والسكان وغيرها.

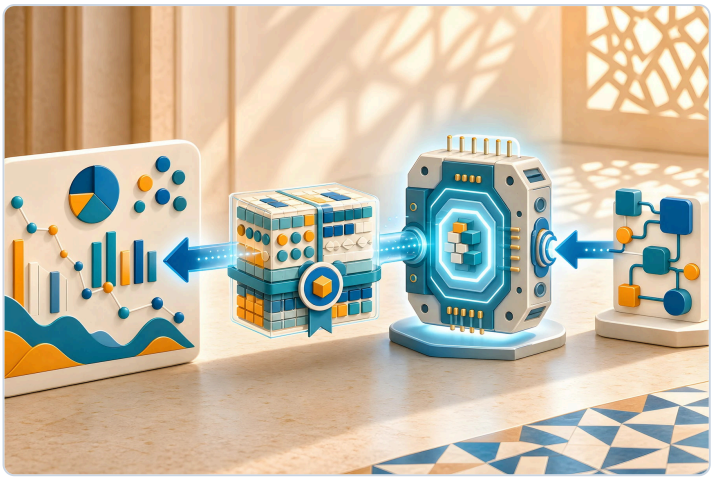
مصطلحات أساسية

واجهة برمجة التطبيقات (API) – قواعد تتفاعل بها البرمجيات، تُستخدم لجلب البيانات.

نقطة النهاية (endpoint) – عنوان URL الذي يُرسَل إليه الطلب.

JSON – صيغة شائعة لبيانات الاسم/القيمة.

3. الحصول على البيانات عبر واجهات برمجة التطبيقات



قد توفر API وصولًا برمجيًا إلى بيانات أو وظائف؛ ومدى حداثة البيانات يعتمد على الخدمة.

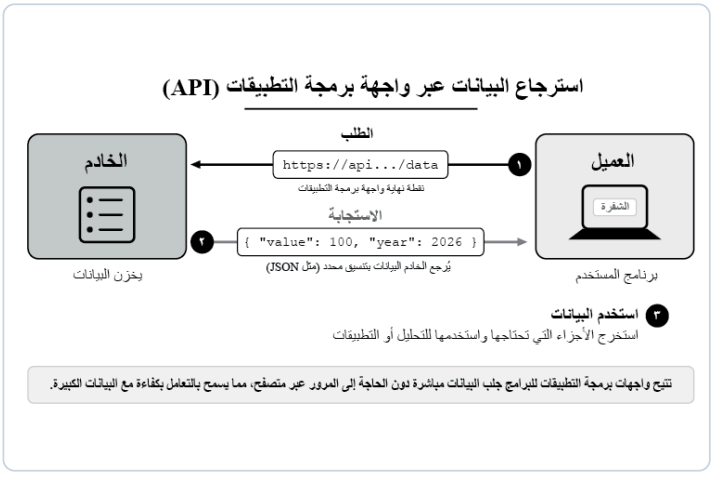
(1) **واجهة برمجة التطبيقات (API)**: مجموعة قواعد تتيح لبرنامج أن يطلب بيانات أو وظائف من برنامج أو خدمة أخرى. ويمكن للبرنامج إرسال الطلب مباشرة إلى API بدل تنفيذ الخطوات يدويًا في صفحة ويب، بما يساعد على تكرار الطلبات ومعالجة النتائج آليًا ضمن حدود الخدمة.

(2) يسير الحصول على البيانات عبر واجهة برمجة التطبيقات وفقًا للتسلسل التالي.

① يرسل العميل طلبًا إلى **نقطة نهاية (Endpoint)**، وهي عنوان أو مسار محدد في API يستقبل نوعًا معينًا من الطلبات.

② يعالج الخادم الطلب، ثم يعيد استجابة قد تحتوي على بيانات أو رسالة خطأ، بصيغة تحددها الخدمة.

③ يقرأ البرنامج الاستجابة، ثم يستخدم البيانات أو يتعامل مع الخطأ بحسب الحالة.



الشكل 5.3.1 – استرجاع البيانات عبر واجهة برمجة التطبيقات: الطلب، والاستجابة، والاستخدام

(3) **JSON (JavaScript Object Notation)** صيغة نصية شائعة لتمثيل البيانات المهيكلة باستخدام كائنات ومصفوفات وقيم مختلفة. تدعمها لغات وأدوات كثيرة، لكنها ليست الصيغة الوحيدة التي قد تستخدمها API.

(4) لا يلغي الوصول عبر API شروط الاستخدام أو الترخيص. اتبع حدود الطلبات وسياسات الحفظ والنشر، وتحقق من نطاق إعادة الاستخدام المسموح.

💡 توقّف وفكّر

البيانات "المفتوحة" لا تزال لها قواعد – ما الأمران اللذان يجب عليك التحقق منهما قبل استخدامها؟

4. استخدام البيانات والإشارة إلى المصدر



استخدم البيانات بمسؤولية وأشر إلى مصدرها.

(1) للبيانات المفتوحة ترخيص أو شروط تحدد ما يسمح به عند الوصول إليها وإعادة استخدامها وإعادة توزيعها. لذلك يجب قراءة الشروط الخاصة بالمجموعة قبل الاستخدام.

(2) استخدم البيانات وفق الترخيص، وانسبها إلى المصدر بالطريقة المطلوبة. وقد يتضمن الإسناد أو الاستشهاد: الجهة الناشرة، واسم مجموعة البيانات، والإصدار أو تاريخ التحديث أو الوصول، ورابط المصدر، وفق متطلبات الجهة ومعيار الاستشهاد.

(3) لا يثبت ذكر المصدر وحده موثوقية البيانات، لكنه يساعد الآخرين على العثور عليها وتقييمها ومراجعة التحليل. وتظل جودة البيانات والمنهج بحاجة إلى تقييم مستقل.

الفكرة الرئيسة

البيانات المفتوحة قوية لكنها لا تزال تخضع لقواعد. اختر مزودًا موثوقًا يناسب غرضك (Kaggleg UN Datag World Bank Open Data)، واجلبها عبر المتصفح أو عبر واجهة برمجة تطبيقات – حيث يرسل العميل طلبًا إلى نقطة نهاية ويُعيد الخادم البيانات، عادةً بصيغة JSON – واتبع دائمًا شروط الاستخدام وأشر إلى المصدر حتى يمكن الوثوق بتحليلك والتحقق منه.

توقّف وفكّر

في استدعاء واجهة برمجة التطبيقات، من الذي يرسل الطلب ومن الذي يُعيد البيانات؟

مثال محلول

(1) ضع علامة ○ إذا كانت العبارة صحيحة أو × إذا كانت خاطئة أمام كل عبارة (أ - د).

أ تنشر World Bank Open Data إحصاءات عن الاقتصاد والسكان والتعليم وما إلى ذلك لدول العالم.

ب باستخدام واجهة برمجة التطبيقات، يمكن الحصول على البيانات اللازمة مباشرة دون المرور عبر متصفح.

جـ طالما أن البيانات مفتوحة، يمكن استخدامها بحرية دون التحقق من شروط الاستخدام.

د عند استخدام البيانات، يُطلَب الإشارة إلى المزوّد، واسم البيانات، وتاريخ الحصول عليها، وعنوان URL، وما إلى ذلك كمصدر.

(2) طابق كل وصف (1 - 3) مع مزود البيانات المفتوحة الأنسب من الخيارات أدناه (أ - جـ).

1 ينشر إحصاءات عن الاقتصاد والسكان والتعليم وما إلى ذلك لدول العالم.

2 يوفر إحصاءات دولية تنشرها الأمم المتحدة والوكالات التابعة لها.

3 منصة تُجري مسابقات تحليل البيانات.

[الخيارات] أ UN Data ب World Bank Open Data جـ Kaggle

✓ الحلّ

(1)

- **أ** وصف صحيح لـWorld Bank Open Data. لذلك، ○.
- **ب** وصف صحيح لواجهة برمجة التطبيقات. لذلك، ○.
- **ج** حتى مع البيانات المفتوحة، تختلف شروط الاستخدام لكل مجموعة بيانات، لذا يجب دائمًا التحقق منها قبل الاستخدام. لذلك، ×.
- **د** محتوى صحيح للإشارة إلى المصدر. لذلك، ○.

(2)

- **1:** إحصاءات عن دول العالم هي World Bank Open Data. **ب**
- **2:** بيانات من الأمم المتحدة والوكالات التابعة لها هي UN Data. **أ**
- **3:** المنصة التي تُجري مسابقات تحليل البيانات هي Kaggle. **ج**

تدرّب

1 أجب عن الأسئلة التالية.

1. ما اسم بوابة البيانات المفتوحة التابعة للبنك الدولي التي تنشر إحصاءات عن الاقتصاد والسكان والتعليم وما إلى ذلك لدول العالم؟
2. ما المصطلح الذي يشير إلى قواعد تفاعل أجزاء البرمجيات مع بعضها البعض، والذي يُستخدم أيضًا على نطاق واسع في خدمات الويب للحصول على البيانات؟
3. اذكر صيغة نصية شائعة قد تستخدمها API لتمثيل البيانات المهيكلة.
4. ما المصطلح الذي يعني ذكر معلومات المصدر بالطريقة التي يطلبها الترخيص أو معيار الاستشهاد؟

2 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف تسلسل الحصول على البيانات عبر واجهة برمجة التطبيقات بأكبر قدر من الدقة.

- **أ** يرسل العميل طلبًا إلى الخادم، ويُعيد الخادم البيانات بصيغة مثل JSON.
- **ب** يستمر الخادم من جانب واحد في إرسال البيانات إلى العميل.
- **ج** يتبادل العملاء البيانات مباشرة مع بعضهم البعض.
- **د** الخادم يخزّن البيانات فقط؛ ولا يمكن للعملاء استرجاعها.

(2) لكل من الغرضين (1، 2)، اختر مزود البيانات المفتوحة الأنسب من الخيارات أدناه (أ - ج).

- **1** تريد مقارنة الناتج المحلي الإجمالي بين الدول.
- **2** تريد العثور على مجموعات بيانات من مجالات متنوعة لدراسة التعلّم الآلي.

[الخيارات] أ UN Data ب World Bank Open Data ج Kaggle

(3) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف استخدام البيانات المفتوحة بأكبر قدر من الدقة.

- **أ** يمكن استخدام البيانات المفتوحة بحرية، لذا لا حاجة للتحقق من شروط الاستخدام.
- **ب** الإشارة إلى المصدر مطلوبة فقط للبيانات المنشورة مقابل رسوم.
- **ج** حتى عند استخدام البيانات المفتوحة، يُطلَب الإشارة إلى المزوّد، واسم البيانات، وتاريخ الحصول عليها، وعنوان URL، وما إلى ذلك كمصدر.
- **د** بالنسبة للبيانات التي يتم الحصول عليها عبر واجهة برمجة تطبيقات، لا حاجة لاتباع شروط الاستخدام.

📝 سؤال على نمط الامتحان

اشرح لماذا يجب على المحلل التحقق من شروط الاستخدام والإشارة إلى المصدر حتى عندما تكون البيانات مجانية ومفتوحة. **[6]**

استعن بـ: حقك في استخدام البيانات، والموثوقية، والسماح للآخرين بالتحقق.

💡 توقّف وفكّر

أي مزوّد يناسب أي غرض – وهل ستستخدم متصفحًا أم واجهة برمجة تطبيقات؟

⚙️ فكّر كمهندس: ابحث ثم قرر

من أجل مشروع مدرسي، تريد إظهار كيف تغيّر الوصول إلى الإنترنت في مصر خلال السنوات العشر الماضية مقارنة بدولتين مجاورتين. يجب عليك اختيار مصدر بيانات مفتوحة وطريقة للحصول عليها.

1 · **افحص مصدرين.** ابحث عن مزودَين مرشحين لهذا السؤال بالتحديد (على سبيل المثال UN Datag World Bank Open Data). لكل منهما، دوّن ما إذا كان يحتوي فعليًا على أرقام الوصول إلى الإنترنت حسب الدولة والسنة، ومدى حداثة آخر سنة متاحة.

2 · **حلّل الملاءمة والقواعد.** قارن بين المصدرين من ناحية لا يذكرها جدول الدرس – مثل إلى أي مدى تمتد البيانات في الماضي، أو ما إذا كانت شروط استخدامه تسمح لك بإعادة نشر رسم بياني في تقرير عام. اذكر خطرًا واحدًا لاختيار المصدر الخاطئ هنا.

3 · قرّر. اختر مصدرًا وطريقة وصول وبرّر كليهما. ثم اكتب بيانات المصدر وفق متطلبات الترخيص وطريقة الاستشهاد المعتمدة في الكتاب. قارن اختيارك مع زميل وحددا أي مصدر أنسب للسؤال ولماذا.

☐ **خذ أول مجموعة بيانات تجدها** ☐ **اختر مصدرًا موثوقًا واتبع قواعده**

قدّم دليلًا يدعم إجابتك.

هل تواجه صعوبة؟ ابدأ من السؤال، لا من المصدر: اذكر بالضبط الحقول التي تحتاجها (الدولة، السنة، معدل الوصول إلى الإنترنت)، ثم احتفظ فقط بالمزودين الذين يحتوون فعليًا على الحقول الثلاثة جميعها – وتحقق من شروط كل منهم قبل الالتزام.

مصطلحات أساسية

شروط الاستخدام – القواعد المحددة لكل مجموعة بيانات.

الإشارة إلى المصدر – المزوّد، الاسم، التاريخ، عنوان URL.

🌍 طبّق ما تعلمته

يعرض تطبيق طقس توقعات اليوم من خدمة عامة. صف الطلب والاستجابة بين التطبيق والخادم، واذكر صيغة بيانات محتملة مثل JSON، مع التنبيه إلى أن الصيغة تعتمد على الخدمة.

❓ إجابة السؤال الرئيس

أجاب الدرس عن السؤال الرئيس: كيف نختار بيانات مفتوحة ونصل إليها ونستخدمها؟ البيانات المفتوحة متاحة وفق ترخيص أو شروط تسمح بإعادة الاستخدام، وليست كل البيانات المجانية مفتوحة. ويجب تقييم الجهة الناشرة وطريقة الجمع والتعريفات والحداثة والملاءمة للسؤال. قد يوفر المصدر تنزيلًا مباشرًا أو API؛ فيرسل العميل طلبًا إلى نقطة نهاية ويعيد الخادم استجابة قد تحتوي على JSON أو صيغة أخرى أو رسالة خطأ. ولا يلغي الوصول عبر API الترخيص أو حدود الاستخدام. اتبع الشروط وانسب البيانات بالطريقة المطلوبة، مع تقييم جودة البيانات والمنهج بصورة مستقلة.

تمارين

1 اختبر فهمك: أجب عن الأسئلة الآتية دون الرجوع إلى قسم «ملحوظة مهمة»، ثم راجع إجاباتك.

2 اقرأ الفقرة التالية وأجب عن كل سؤال.

لاستخدام البيانات المفتوحة يجب معرفة المصدر وطريقة الوصول وشروط الاستخدام. يمكن العثور على مؤشرات دولية في بوابات مثل (1)، مع فحص تعريف المؤشر ومصدره.

وقد يوفر المصدر (2) ليتلقى البرنامج استجابة بصيغة مثل (3) بحسب الخدمة. ويجب دائمًا التحقق من (4) الخاصة بالمجموعة، ثم تقديم (5) إلى المصدر وفق الترخيص ومعيار الاستشهاد.

1. املأ الفراغات (1) - (5).

3 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف Kaggle بأكبر قدر من الدقة.

أ بوابة يديرها البنك الدولي تنشر إحصاءات لدول العالم.

ب موقع للإحصاءات الدولية تديره الأمم المتحدة.

ج منصة تُجري مسابقات تحليل البيانات، تُتاح فيها مجموعات بيانات في مجالات متنوعة للعموم.

د نظام يسجّل تلقائيًا سجلات تصفح المواقع الإلكترونية.

(2) من بين الخيارات التالية (أ - د)، اختر الخيار الذي لا يُعد وصفًا مناسبًا للإشارة إلى المصدر.

أ الإشارة إلى المصدر لا تُثبت وحدها موثوقية البيانات، لكنها تتيح للآخرين العثور عليها وتقييمها.

ب الإشارة إلى المصدر مهمة للسماح للآخرين بالتحقق من التحليل.

ج تشمل المصادر مزود البيانات، واسم البيانات، وتاريخ الحصول عليها، وعنوان URL، وما إلى ذلك.

د عند استخدام البيانات المفتوحة، لا حاجة للإشارة إلى المصدر.

(3) من بين الخيارات التالية (أ - د)، اختر الخيار الذي لا يُعد نقطة تنبيه مناسبة عند استخدام واجهة برمجة تطبيقات.

أ استخدم واجهة برمجة التطبيقات وفقًا لشروط الاستخدام التي يحددها المزوّد.

ب تجنّب إرسال طلبات مفرطة في وقت قصير.

ج تحقق مسبقًا من نطاق الاستخدام المسموح به للبيانات التي تم الحصول عليها.

د بسبب طريقة عمل واجهات برمجة التطبيقات، يمكن استخدامها دون التحقق من شروط الاستخدام.

⭐ الخلاصة

تذكّر:
اختر مصدر بيانات مفتوحة موثوقًا يناسب غرضك (World Bank Open Data، UN Datag، Kaggleg)، واجلبها عبر المتصفح أو واجهة برمجة التطبيقات (يطلب العميل نقطة نهاية؛ ويُعيد الخادم JSON)، واتبع دائمًا شروط الاستخدام وأشر إلى المصدر.

⭐ فكّر وتحدَّ نفسك

تأمّل: فكّر في رسم بياني رأيته على الإنترنت بدون مصدر. هل وثقت به – وما السطر الواحد الذي كان سيغيّر ذلك؟

تحدٍّ: يُسمح لك بذكر سطر مصدر واحد فقط لرسم بياني مبني من مجموعة بيانات للبنك الدولي قمت بتنزيلها اليوم. اكتب سطر الإشارة إلى المصدر هذا، وقل أي عنصر واحد لن تحذفه أبدًا ولماذا.