

الدرس 5-2

تنظيف البيانات وتحويلها

أهداف التعلم

- شرح كيفية التعامل مع القيم المفقودة، والقيم الشاذة (المتطرفة)، والبيانات المكررة عند تنظيف مجموعة البيانات.
- وصف عمليات تحويل أنواع البيانات (الربط والتجميع).

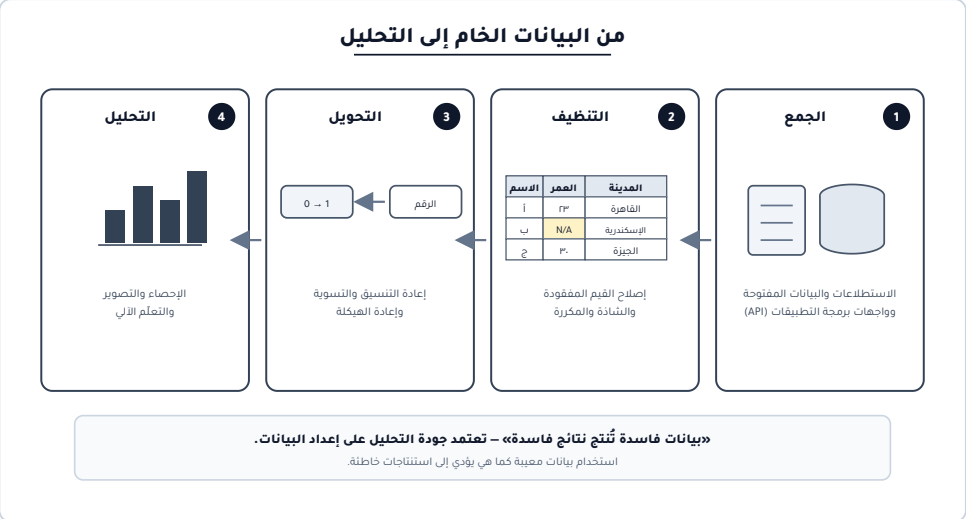
تصل البيانات الحقيقية فوضوية: خلايا فارغة، قيمة أكبر بعشر مرات من اللازم، نفس الصف مُدخَل مرتين، تواريخ مكتوبة بثلاث طرق مختلفة. قبل أن يُوثَق بأي تحليل، يجب تنظيف البيانات وتحويلها لتناسب السؤال المطروح. هناك قاعدة في علوم الحاسب – "مدخلات خاطئة – مخرجات خاطئة" – تعني أن الحساب الدقيق على بيانات معيبة لا يزال يعطي إجابة معيبة. هذا الدرس يتناول كيفية تحويل البيانات الخام إلى بيانات يمكن الاعتماد عليها فعليًا.

؟ السؤال الرئيس: لماذا يجب تنظيف البيانات وتحويلها قبل التحليل، وما الخيارات التي ينطوي عليها كل إصلاح؟

📌 ملحوظة مهمّة

1. مراحل تنظيف البيانات وتحويلها

(1) قد تحتاج البيانات المجمعة إلى تنظيف أو تحويل قبل التحليل. **تنظيف البيانات** هو اكتشاف مشكلاتها وتصحيحها أو التعامل معها بطريقة مناسبة، أما **تحويل البيانات** فيعد الصيغ أو البنية لتناسب السؤال وطريقة التحليل.



الشكل 5.2.1 – من البيانات الخام إلى التحليل: الجمع، التنظيف، التحويل، التحليل

(2) تؤثر جودة التحضير بقوة في جودة النتائج، لكن لا توجد سلسلة إصلاح واحدة تناسب كل البيانات: فالقرارات تعتمد على نوع المشكلة وسؤال التحليل.

2. التعامل مع القيم المفقودة



عالج القيم الفارغة وقيّم القيم الشاذة قبل التحليل.

⭐ خريطة الدرس

الفكرة الأساسية:

نادرًا ما تكون البيانات الخام جاهزة للاستخدام مباشرة. يعالج التنظيف القيم المفقودة والقيم الشاذة والتكرارات؛ ويحوّل التحويل الأنواع، ويعيد ضبط المقياس، ويعيد تشكيل البيانات لتناسب الغرض. "مدخلات خاطئة – مخرجات خاطئة" – تعتمد جودة أي تحليل على هذا التحضير.

المفاهيم الأساسية:

- تنظيف البيانات / تحويل البيانات
- القيم المفقودة، القيم الشاذة، التكرارات
- تحويل نوع البيانات
- التحويل الكمي / التوحيد القياسي
- إعادة التشكيل (المحور، الربط، التجميع)

مصطلحات أساسية

تنظيف البيانات – إصلاح القيم المفقودة والقيم الشاذة والتكرارات.

تحويل البيانات – إعادة تشكيل/ضبط مقياس البيانات لتناسب الغرض.

💡 توقّف وفكّر

خلية فارغة في استبيان – هل نحذف الصف، أم نملؤها، أم نضع عليها علامة؟ ما الذي يحدد ذلك؟

(1) قد تسبب القيم المفقودة مشكلات في بعض الحسابات أو تغير النتائج بحسب مقدارها وسببها ونمطها. ومن الطرق الشائعة الحذف أو التعويض أو الاحتفاظ بمؤشر يدل على أن القيمة مفقودة، وقد توجد طرق أخرى بحسب التحليل.

الاستجابة	الوصف	متى تُطبَّق
الحذف	إزالة سجل أو متغير إذا كان ذلك مناسبًا ولا يفقد معلومات مهمة أو يسبب تحيزًا مهمًا	قد يناسب عندما يكون الفقد قليلًا وفقد السجلات لا يسبب تحيزًا أو خسارة مهمة
التعويض	تقدير قيمة بديلة بطريقة مناسبة، وقد تكون بسيطة مثل الوسيط أو أكثر تقدمًا	يُختار بعد فهم سبب الفقد ونمطه وطريقة التحليل، مع فحص أثر التعويض في التوزيع والنتائج
وضع علامة	إنشاء مؤشر يوضح أن القيمة كانت مفقودة، أو استخدام فئة مناسبة إذا كان الغياب نفسه يحمل معنى	عندما يكون للغياب نفسه معنى (مثل حقيقة أن شخصًا ما رفض الإجابة)

(2) يعتمد الاختيار على مقدار الفقد وسببه ونمطه وغرض التحليل. وقد يغير التعويض البسيط بالمتوسط توزيع البيانات ويقلل التباين، خاصةً إذا كان الفقد كبيرًا؛ لذلك يجب فحص أثر الطريقة في النتائج.

3. التعامل مع القيم الشاذة والبيانات المكررة

(1) **القيم الشاذة** بعيدة عن معظم القيم، لكنها ليست أخطاء بالضرورة؛ فقد تنتج عن خطأ إدخال أو قياس، وقد تكون قيمة حقيقية نادرة. لذلك يجب التحقق من مصدر القيمة وتعريف المتغير قبل تعديلها.

(2) تبدأ معالجة القيم الشاذة بتحديد السبب.

① عندما يكون السبب خطأ في الإدخال أو القياس... صحّح القيمة أو احذفها

② إذا كانت القيمة صحيحة، فلا تحذفها لمجرد أنها بعيدة عن الباقي؛ قرر وفق سؤال التحليل وبسبب تحليلي واضح.

(3) قد تغير السجلات المكررة الحسابات، لكن لا يُحذف سجل مكرر ظاهريًا إلا بعد التأكد أنه تكرار غير مقصود لنفس الملاحظة أو الحدث؛ فقد تمثل السجلات المتشابهة أحداثًا حقيقية منفصلة.

4. تحويل نوع البيانات

(1) يجب الفصل بين **تغيير نوع البيانات**، مثل تحويل نص رقمي إلى رقم، وبين **توحيد الصيغ أو الترميز**، مثل توحيد كتابة التاريخ أو القيم الفئوية. وقد تحتاج البيانات إلى أحد هذه التحويلات أو أكثر.

نوع التحويل	الوصف	مثال
التحويل من نص إلى رقم	تحويل الأرقام المخزَّنة كنصوص إلى قيم رقمية يمكن استخدامها في الحسابات	"١٢٣" ← 123
توحيد صيغة التاريخ	مواءمة التواريخ ذات الصيغ المختلفة في صيغة واحدة	"2026/4/1"، "2026-04-01"، "01 Apr 2026" ← 2026-04-01
توحيد طريقة الكتابة	دمج القيم ذات المعنى الواحد في صيغة كتابة واحدة	مزيج من "ذكر/أنثى" و"M/F" ← موحَّد إلى "ذكر/أنثى"

(2) إذا اختلفت الصيغ أو الترميزات، فقد يعامل البرنامج القيم المتشابهة على أنها مختلفة. وإذا خُزنت الأرقام كنصوص، فقد تفشل بعض الحسابات أو تتعامل الأداة معها بوصفها نصوصًا. لذلك تُفحص الأنواع والصيغ قبل التحليل بحسب الأداة.

مصطلحات أساسية

القيمة المفقودة – قيمة غائبة.

القيمة الشاذة – قيمة بعيدة عن باقي القيم.

القيمة غير الطبيعية – قيمة شاذة ناتجة عن خطأ.



احذف السجلات المكررة فعليًا فقط.

توقّف وفكّر

الطول بالسنتيمتر والوزن بالكيلوغرام – لماذا قد تهيمن الأرقام الأكبر على التحليل؟

5. التحويل الكمي والتوحيد القياسي



التحجيم يغيّر مقياس المتغيرات عندما تكون الخوارزمية حساسة للمقياس.

(1) في بعض الخوارزميات الحساسة للمقياس، قد يكون للمتغير ذي النطاق الأكبر تأثير أكبر لمجرد مقياسه. عندئذ يمكن استخدام طريقة تحجيم مناسبة، مثل تحجيم Min-Max أو التوحيد القياسي.

الطريقة	الوصف	الغرض الرئيسي
تحجيم Min-Max	تحويل البيانات إلى نطاق من 0 إلى 1	وضع المتغيرات في نطاقات متقاربة عندما تحتاج الخوارزمية إلى ذلك
التوحيد القياسي	تحويل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1	التعبير عن بُعد القيمة عن المتوسط بوحدات من الانحراف المعياري

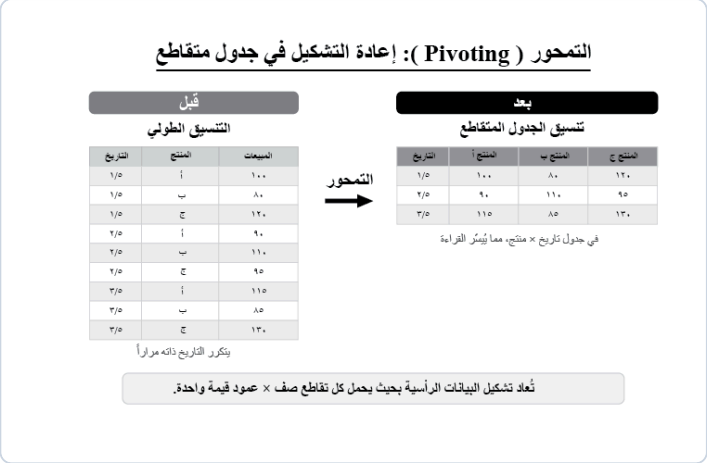
(2) يمكن لتحجيم Min-Max تحويل كل متغير إلى نطاق من 0 إلى 1 باستخدام حديه في البيانات. وقد يساعد ذلك خوارزمية حساسة للمقياس على التعامل مع متغيرات مختلفة دون أن يسيطر أحدها بسبب نطاقه، لكنه ليس مطلوبًا لكل تحليل.

(3) يطرح التوحيد القياسي المتوسط من كل قيمة ثم يقسم على الانحراف المعياري، فيصبح متوسط البيانات المستخدمة في الحساب 0 وانحرافها المعياري 1. وتمثل القيمة الجديدة عدد الانحرافات المعيارية عن المتوسط، مع اعتماد التفسير على شكل التوزيع.

6. إعادة تشكيل البيانات حسب الغرض

(1) **إعادة تشكيل البيانات**: تغيير بنية الجدول أو دمج الجداول أو تلخيصها بما يناسب السؤال. ومن عملياتها التحويل المحوري (Pivot) والربط والتجميع.

العملية	الوصف	مثال
التحويل المحوري (Pivot)	تحويل البيانات بين شكل طويل وعريض وفق صفوف وأعمدة محددة	إعادة تشكيل بيانات التاريخ والمنتج والمبيعات المرتبة عموديًا إلى جدول "التاريخ × المنتج"
(الربط)	دمج بيانات من جداول متعددة باستخدام مفتاح أو شرط مطابق	ربط سجل الطلاب وورقة الدرجات عبر "رقم الطالب" في جدول واحد
(التجميع)	حساب المجاميع والمتوسطات وما إلى ذلك لكل مجموعة وتلخيصها	حساب الإجمالي الشهري من المبيعات اليومية



الشكل 5.2.2 – تحويل المحور: إعادة تشكيل البيانات ذات الصيغة الطويلة إلى جدول متقاطع

(2) تعتمد العملية التي يجب إجراؤها على غرض التحليل. على سبيل المثال، إذا أردت رؤية "اتجاهات المبيعات الشهرية"، فأنت بحاجة إلى تجميع بيانات المبيعات اليومية حسب الشهر. من المهم توضيح غرض التحليل أولًا، ثم التخطيط لكيفية إعادة تشكيل البيانات.

الفكرة الرئيسة

التحضير يحدد الجودة. أصلح القيم المفقودة (احذف أو عوّض أو ضع علامة)، واحكم على القيم الشاذة حسب السبب، وأزل التكرارات الحقيقية، وحوّل أنواع البيانات ووحّد الصيغ، وأعد ضبط المقياس بالتحويل الكمي أو التوحيد القياسي حتى لا يهيمن أي متغير بحكم حجمه، وأعد التشكيل (المحور، الربط، التجميع) ليناسب السؤال – مدخلات خاطئة – مخرجات خاطئة.

توقّف وفكّر

هل يوم مبيعات ضخم في متجر ما دائمًا خطأ – أم قد يكون حقيقيًا؟

مثال محلول

(1) ضع علامة ○ إذا كانت العبارة صحيحة أو × إذا كانت خاطئة أمام كل عبارة (أ - د).

أ تنظيف البيانات هو عمل يُجرى قبل جمع البيانات.

ب استجابات القيم المفقودة هي الحذف والتعويض ووضع العلامة – ثلاث استجابات في المجموع.

جـ جميع القيم الشاذة ناتجة عن أخطاء في الإدخال أو القياس، لذا يجب حذفها دائمًا.

د التوحيد القياسي هو معالجة تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1.

(2) طابق كل وصف (1 - 3) مع المعالجة الأنسب من الخيارات أدناه (أ - ج).

1 تحويل البيانات إلى نطاق من 0 إلى 1

2 معالجة تربط مجموعات بيانات مختلفة عبر عنصر مشترك

3 معالجة تحسب المجاميع والمتوسطات وما إلى ذلك لكل مجموعة وتلخّصها

[الخيارات] أ التجميع ب الربط جـ التحويل الكمي

✓ الحلّ

(1)

أ تنظيف البيانات هو عمل ترتيب البيانات المجمَّعة، ويُجرى بعد الجمع. لذلك، x.

ب صحيح كاستجابات للقيم المفقودة. لذلك، ○.

جـ تشمل القيم الشاذة كلًا من القيم غير الطبيعية الناتجة عن أخطاء الإدخال والقيم التي تعكس الواقع. لا تُحذف دائمًا. لذلك، x.

د تعريف صحيح للتوحيد القياسي. لذلك، ○.

(2)

1: التحويل إلى 0-1 هو التحويل الكمي. **جـ**

2: الربط عبر عنصر مشترك هو الربط. **ب**

3: التلخيص حسب المجموعة هو التجميع. **أ**

📝 سؤال على نمط الامتحان

اشرح، باستخدام "مدخلات خاطئة – مخرجات خاطئة"، لماذا يهم تحضير البيانات بقدر أهمية التحليل نفسه. **[6]**

استعن بـ: إصلاح واحد للتنظيف وتحويل واحد.

تدرّب

1 أجب عن الأسئلة التالية.

1. ما المصطلح الذي يشير إلى المعالجة التي تملأ الأجزاء المفقودة من البيانات بقيم مثل المتوسط أو الوسيط؟
2. ما المصطلح الذي يشير إلى المعالجة التي تحوّل البيانات إلى نطاق من 0 إلى 1؟
3. ما المصطلح الذي يشير إلى المعالجة التي تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1؟
4. ما المصطلح الذي يشير إلى العملية التي تربط مجموعات بيانات متعددة عبر عنصر مشترك؟

2 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي لا يُعد استجابة مناسبة للقيم المفقودة.

أ عندما تكون القيم المفقودة قليلة والتأثير على الكل صغيرًا، احذف الصفوف التي تحتوي على قيم مفقودة.

ب عندما تكون القيم المفقودة موزعة عشوائيًا، املأ الأجزاء المفقودة بقيم مثل المتوسط.

جـ عندما يكون للغياب نفسه معنى، اترك علامة تشير إلى أن القيمة كانت مفقودة وحلّل البيانات.

د عوّض بالمتوسط وحلّل البيانات في العناصر التي يكون معظم بياناتها مفقودًا.

(2) لكل من الموقفين (1، 2)، اختر المعالجة الأنسب للبيانات من الخيارات أدناه (أ، ب).

1 تريد مواءمة بيانات التاريخ ذات الصيغ المختلطة مثل "2026/4/1" و"01-04-2026" و"01 Apr 2026".

2 تريد مقارنة متغيرات ذات وحدات ومقاييس مختلفة معًا، مثل الطول (بالسنتيمتر) والوزن (بالكيلوغرام).

[الخيارات] أ تحويل نوع البيانات (توحيد صيغة التاريخ) ب التحويل الكمي

(3) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف التعامل مع القيم الشاذة بأكبر قدر من الدقة.

أ جميع القيم الشاذة أخطاء في البيانات، لذا احذفها كلها فور اكتشافها.

ب بالنسبة للقيم الشاذة، حدّد السبب أولًا؛ صحّحها أو احذفها إذا كانت ناتجة عن أخطاء إدخال، واحتفظ بها من حيث المبدأ إذا كانت تعكس الواقع.

جـ القيم الشاذة لا تؤثر على التحليل، لذا لا حاجة لمعالجة خاصة.

د يمكن دائمًا حل القيم الشاذة عن طريق استبدالها بالمتوسط.

💡 توقّف وفكّر

إذا كان معظم العمود فارغًا، فهل ملؤه بالمتوسط يساعد – أم يخترع بيانات؟

⚙️ فكّر كمهندس: ابحث ثم قرر

جمع صفك استبيانًا عن وقت الشاشة اليومي، لكن الجدول الخام فوضوي: بعض الخلايا فارغة، وإدخال واحد يقرأ "9999" ساعة، والتواريخ مكتوبة بثلاث طرق مختلفة، وصفان يبدوان متطابقين. تقوم بتحضير البيانات للتحليل.

1 · **افحص البيانات.** اذكر كل مشكلة يمكنك رؤيتها في الجدول أعلاه؛ ولكل مشكلة، حدّد فئتها (قيمة مفقودة، قيمة شاذة، تكرار، أو مشكلة صيغة) واذكر بعبارة واحدة كيف ستشوّه التحليل إذا تُركت دون إصلاح.

2 · قرّر إصلاحًا وخطره. اختر طريقة التعامل مع القيم المفقودة بعد النظر إلى مقدار الفقد وسببه ونمطه، لا النسبة وحدها. وبالنسبة إلى «9999 ساعة»، تحقّق من مصدرها وتعريف المتغير قبل تقرير تصحيحها أو حذفها، فقد تكون خطأً أو وحدة مختلفة أو رمزًا ذا معنى.

3 · خطط للتحويل. حدّد تحويل الصيغة المطلوب لتجميع التواريخ، ثم اسأل: هل يحتاج هذا التحليل أصلًا إلى تحجيم عمود وقت الشاشة؟ وإذا نعم، فما الطريقة المناسبة؟ قارن الخطة مع زميل وحددا الإصلاح الأكثر احتمالًا لتشويه النتائج.

☐ **تحليل الجدول الخام كما هو** ☐ **تنظيفه وتحويله أولًا**

قدّم دليلًا يدعم إجابتك.

هل تواجه صعوبة؟ لا يوجد ترتيب إلزامي واحد لكل حالات التنظيف. افهم المشكلة أولًا، ووحّد الصيغ اللازمة، وتحقق من القيم غير المعتادة، وعالج الفقد، ولا تحذف إلا التكرارات غير المقصودة بعد التحقق منها.

🌍 طبّق ما تعلمته

يسرد جدول مبيعات متجر مبيعات كل يوم للمنتجات A Bg Cg في صفوف منفصلة، لكن المدير يريد صفًا واحدًا لكل يوم مع عمود لكل منتج. سمِّ عملية إعادة التشكيل المطلوبة، وسمِّ العملية الأخرى المطلوبة للحصول على الإجمالي الشهري لكل منتج.

❓ إجابة السؤال الرئيس

أجاب الدرس عن السؤال الرئيس: لماذا ننظف البيانات ونحوّلها؟ يكتشف التنظيف مشكلات مثل القيم المفقودة وغير المعتادة والتكرارات، ويعالجها بحسب سببها ونمطها وسؤال التحليل؛ فلا يُحذف سجل مكرر ظاهريًا أو قيمة بعيدة قبل التحقق. ويجب الفصل بين تغيير نوع البيانات وتوحيد الصيغ والترميز. وإذا كانت الخوارزمية حساسة للمقياس، يمكن استخدام Min-Max أو التوحيد القياسي، ولا يلزم التحجيم لكل تحليل. كما تعيد عمليات Pivot والربط والتجميع تشكيل الجداول لتناسب السؤال. كل قرار يحتاج إلى تبرير وفحص لأثره في النتائج.

مصطلحات أساسية

المحور – صفوف طويلة ← جدول صفوف × أعمدة.

الربط – ربط مجموعات البيانات عبر عنصر مشترك.

التجميع – التلخيص حسب المجموعة.

تمارين

1 اختبر فهمك: أجب عن الأسئلة الآتية دون الرجوع إلى قسم «ملحوظة مهمة»، ثم راجع إجاباتك.

2 اقرأ الفقرة التالية وأجب عن كل سؤال.

قد تحتاج البيانات إلى (1) لاكتشاف مشكلاتها والتعامل معها، و(2) لتغيير الصيغ أو البنية بما يناسب التحليل. ومن طرق التعامل مع الفقد (3) إلى جانب الحذف أو الاحتفاظ بمؤشر للفقد. وإذا كانت الخوارزمية حساسة للمقياس، يمكن استخدام (4) لتحويل القيم إلى نطاق 0-1، أو (5) لتحويلها إلى عدد الانحرافات المعيارية عن المتوسط.

1. املأ الفراغات (1) - (5).

3 أجب عن الأسئلة التالية.

(1) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يمثل تحويل نوع البيانات.

أ ملء القيم المفقودة بالمتوسط.

ب توحيد صيغ مثل "2026/4/1" و"01 Apr 2026" إلى "2026-04-01".

جـ مواءمة مقاييس الطول والوزن إلى نطاق بين 0 و1.

د تجميع المبيعات اليومية في إجماليات شهرية.

(2) من بين الخيارات التالية (أ - د)، اختر الخيار الذي يصف التحويل الكمي والتوحيد القياسي بأكبر قدر من الدقة.

أ التحويل الكمي هو معالجة تحوّل البيانات إلى صيغة متوسطها 0 وانحرافها المعياري 1.

ب التوحيد القياسي هو معالجة تحوّل البيانات إلى نطاق من 0 إلى 1.

جـ يُستخدم التحويل الكمي لمواءمة البيانات ذات الوحدات المختلفة في صورة قابلة للمقارنة.

د يُستخدم التوحيد القياسي لتكبير مقياس المتغيرات.

(3) لكل معالجة (1 - 3)، حدّد ما إذا كانت تقابل المحور أو الربط أو التجميع.

1 ربط سجل الطلاب وورقة الدرجات عبر "رقم الطالب" في جدول واحد.

2 حساب الإجماليات الشهرية من بيانات المبيعات اليومية.

3 إعادة تشكيل مبيعات المنتجات اليومية في صورة جدول "التاريخ × المنتج".

[الخيارات] أ المحور ب الربط جـ التجميع

⭐ الخلاصة

تذكّر:
نظّف أولًا (القيم المفقودة، القيم الشاذة، التكرارات)، ثم حوّل (حوّل الأنواع، طبّق التحويل الكمي أو التوحيد القياسي، أعد التشكيل بالمحور والربط والتجميع). كل إصلاح هو حكم يحدده الغرض – مدخلات خاطئة – مخرجات خاطئة.

⭐ فكّر وتحدَّ نفسك

تأمّل: لماذا قد يؤدي "ملء" البيانات المفقودة أحيانًا إلى تضليل أكبر من تركها فارغة؟

تحدٍّ: لديك عمود استبيان واحد 70% من إجاباته فارغة. ناقش ما إذا كنت ستعوّض أو تضع علامة أو تحذف العمود، واذكر الشرط الوحيد الذي قد يغيّر اختيارك.